# 基于 RAG 的高职机电专业智能教学辅助系统设计与实现


- 答辩人：索建华
- 指导老师：高文超

01
研究背景与现状

02
研究内容与技术路线

03
当前进展

04
创新点

05
参考文献

06
后续工作计划

01

# 研究背景与现状

# 时代背景：教育数字化与 AI 技术爆发

战略部署： “全面推进教育数字化”是党的二十大报告做出的重大战略部署。

技术突破： 2025 年初， DeepSeek-R1 开源，以“低训练成本 + 强推理能力”打破 OpenAI 技术壁垒。



# 国内高校大模型应用现状与典型案例

| 单位 | 名称 | 主要功能 |
| --- | --- | --- |
| 中国人民大学 | DeepSeek 版 e 问 e 答 | 科研项目辅助、学术资源分析 |
| 北京师范大学 | 智能“课程中心”助教 | 学业规划、知识问答、资源推荐、论文润色、写作指导、习题推荐 |
| 北京邮电大学 | “码上”平台 | 编程辅导、教学管理、资源推荐 |
| 北京交通大学 | 智慧教学课程平台 | AI 助教、 AI 教案、 AI 图谱、 AI 伴学等 |
| 中国农业大学、中央民族大学 | | 介绍学校特色专业和校园文化 |
| 清华大学 | 清小搭 | 智能问答、智能伴学、个人成长云盘 |
| 同济大学 | CivilGPT 大模型 | 土木工程知识问答、知识图融合、文献解读 |

- 辅助教学
- 辅助科研
- 行政管理
- 垂直应用
- …

# 教育数字化下的教学领域私有化大模型应用探索
## ——以北京工业职业技术学院机电专业为例

**高职教学的“两大困境”：教师之困与学生之惑**

### 教师端
- 常态化管理难。
- 学情分析难。
- 备课、答疑、个性化指导受限。

### 学生端
- 个性化学习需求难以解决。
- 学习内驱力严重匮乏。
- 自主学习缺乏良性闭环

### 资源端
- 非结构化数据多样。
- 文本、公式、电路图混排。
- 难以被现有工具利用。

## 教师端

- 智能备课
- 教学辅助
- 学情分析



知识库

## 学生端

- 多模态问答
- 个性化学习
- 自动生成练习题

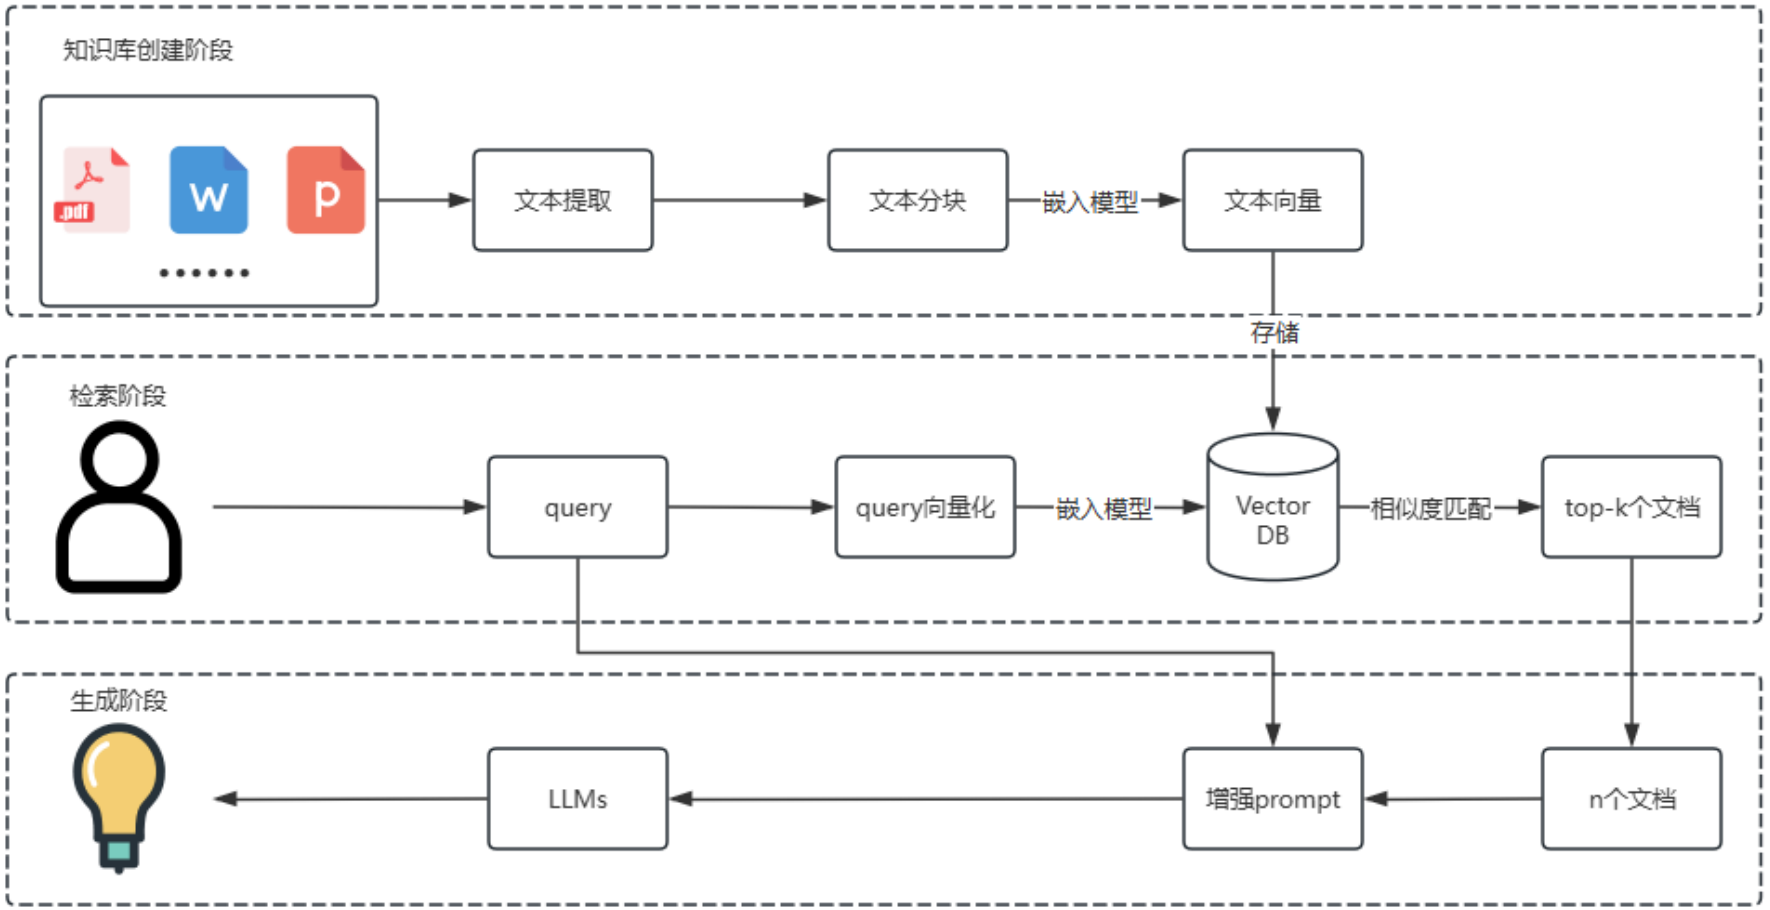
## 理论意义

- 优化视觉处理。
- 多模态场景拓展。

## 实践意义

- 减轻教师负担。
- 提升学生学习体验。

# 检索增强生成 (Retrieval-augmented Generation ， RAG) 技术



# 检索增强生成 (RAG) 研究现状

**Naive RAG**

" 检索 + 生成 " 的简单线性检索机制
缺点：索引语义断崖、噪声干扰、易产生幻觉。

**Advanced RAG**

引入语义 / 命题分块、查询重写、重排序等优化手段，提升检索准确率
缺点：模块间仍是线性流程、调整复杂

**Modular RAG**

将整个 RAG 流程划分为索引、检索前、检索、检索后、重排序、生成等阶段，催生了 Langchain 、 Llama Index 等开发框架

**Graph RAG**

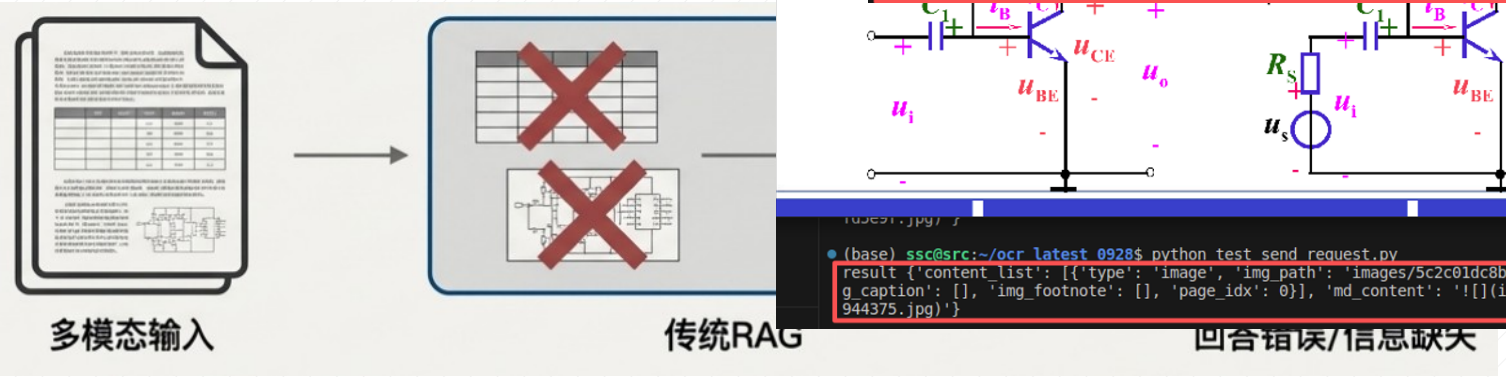
为解决检索知识碎片化问题， Graph RAG 、 Light RAG 为代表的图结构检索增强生成应运而生。
缺点：知识图谱构建成本高、自动抽取噪声大、维护复杂。

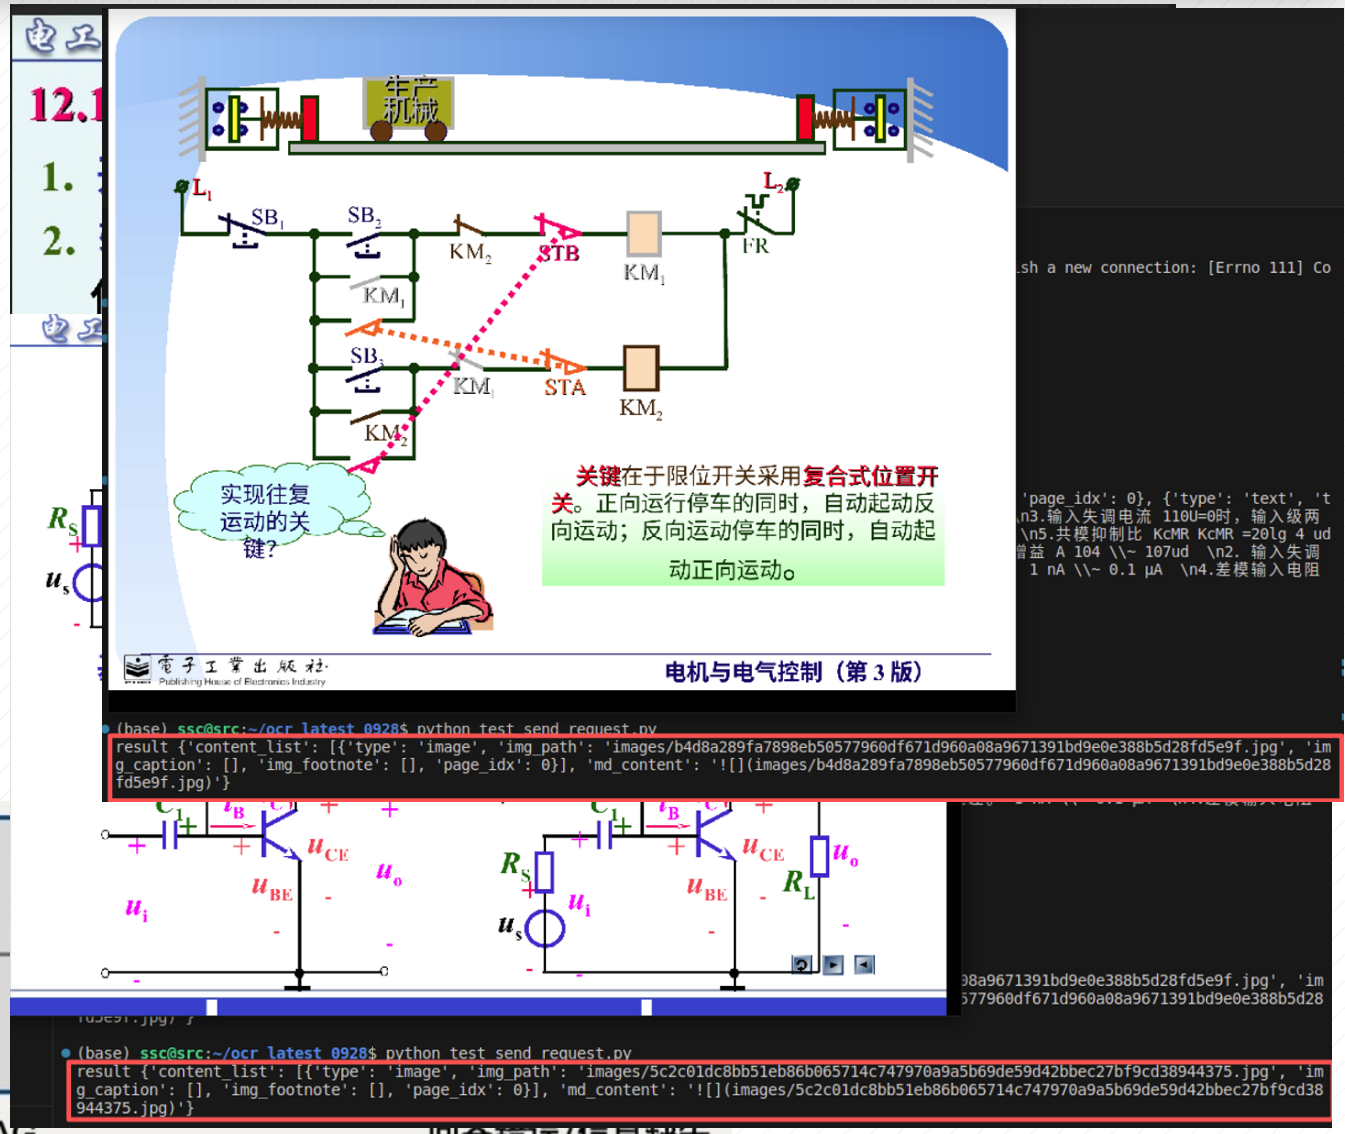
**Multimodal RAG**

随着多模态大模型的发展，开始由单一的文本 RAG ，向图片、视频、音频等模态方向发展。
VisRAG 、 ColPali 、 Colqwen 等视觉检索器被引入到 RAG 中。

## 传统 RAG 在多模态教学资源面前的局限性

1. 海量异构资源：高职教学资源包含 PPT 、PDF 、设备手册、电路图纸等，呈现高度**非结构化、视觉元素众多**的特点，传统 RAG 以**文本为中心**，难以对**多模态知识**进行统一建模。
2. 关键视觉信息丢失：传统的 RAG 在处理**图、表、公式**时，往往会丢弃这些内容，导致**检索精度**不足，**知识融合**效率低。
3. 图文内容缺乏有效对齐：教学资源中的许多知识依赖**图文协同**进行表达，但传统 RAG 难以建立**文本描述与图像关键区域之间的准确对应关系**，进而影响教学理解效果。



02

# 研究内容与技术路线

# 研究内容

数据检索难

数据处理难

**研究内容二**

**基于查询自适应的融合检索算法**

自适应融合检索

多路召回　查询自适应　融合检索

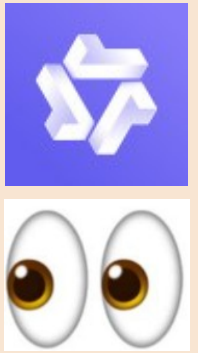
**研究内容一**

**基于文本流与视觉流的多模态知识库建模**

文本流　视觉流

关键词　文本分块　文档页面

**视觉语言模型**



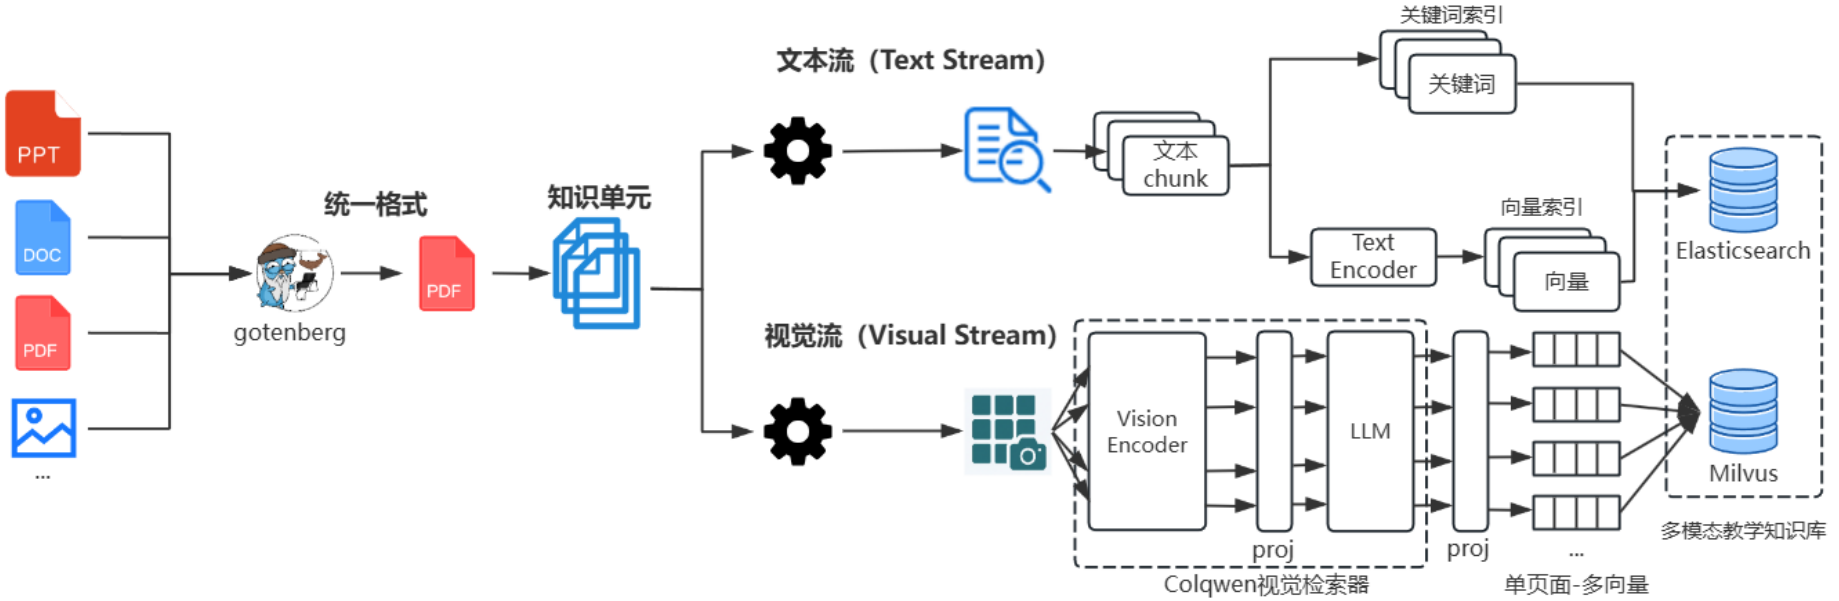
三个内容研究

统筹系统辅助教学智能的专业电机职高向面

# 一、基于文本流与视觉流的多模态知识库建模

## 离线索引

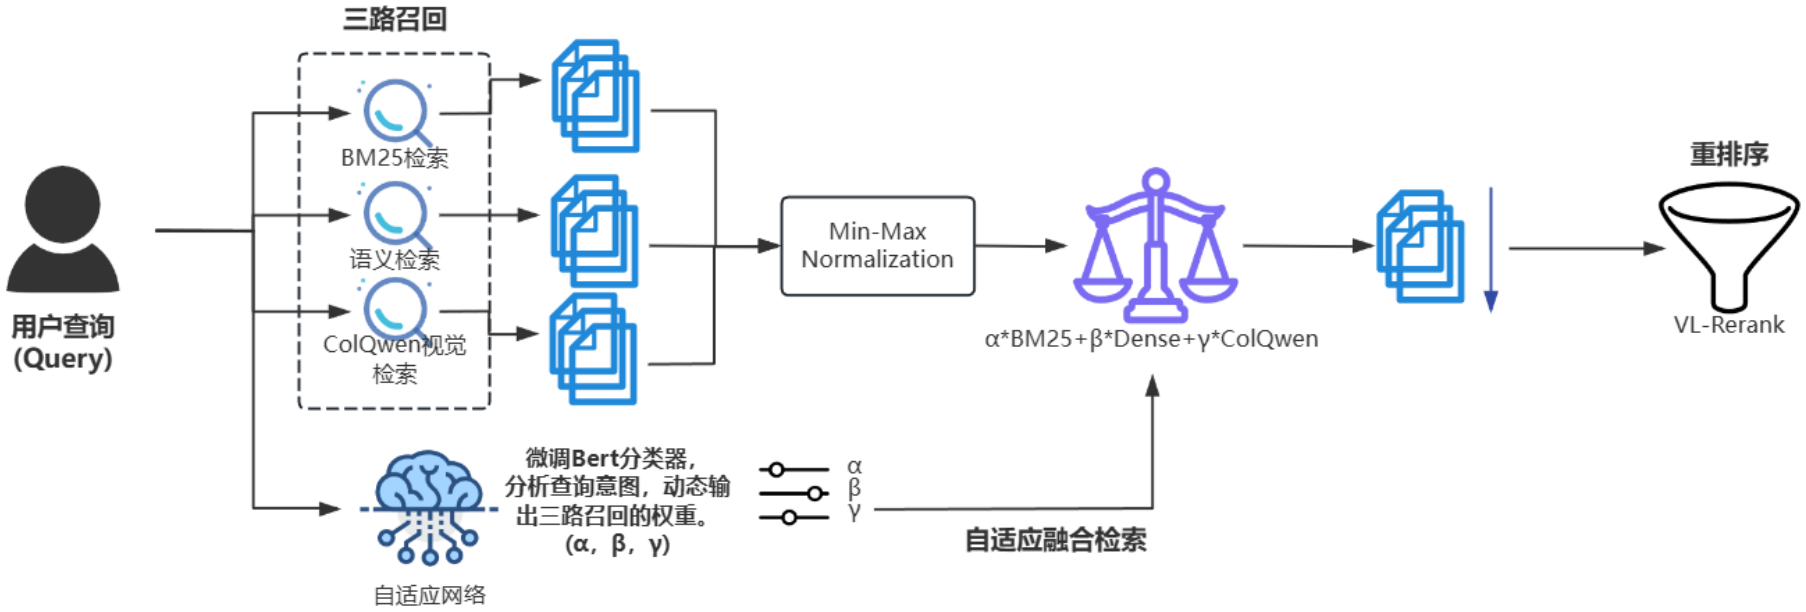
- 统一格式：多种文档类型统一**转化为 PDF** 解析与存储。
- 知识单元：以**文档页面**作为最小知识单元。
- “双流”处理机制：设计**“文本流 + 视觉流”**双路处理，最大化程度保留文档页面信息。



# 二、基于查询自适应的融合检索算法

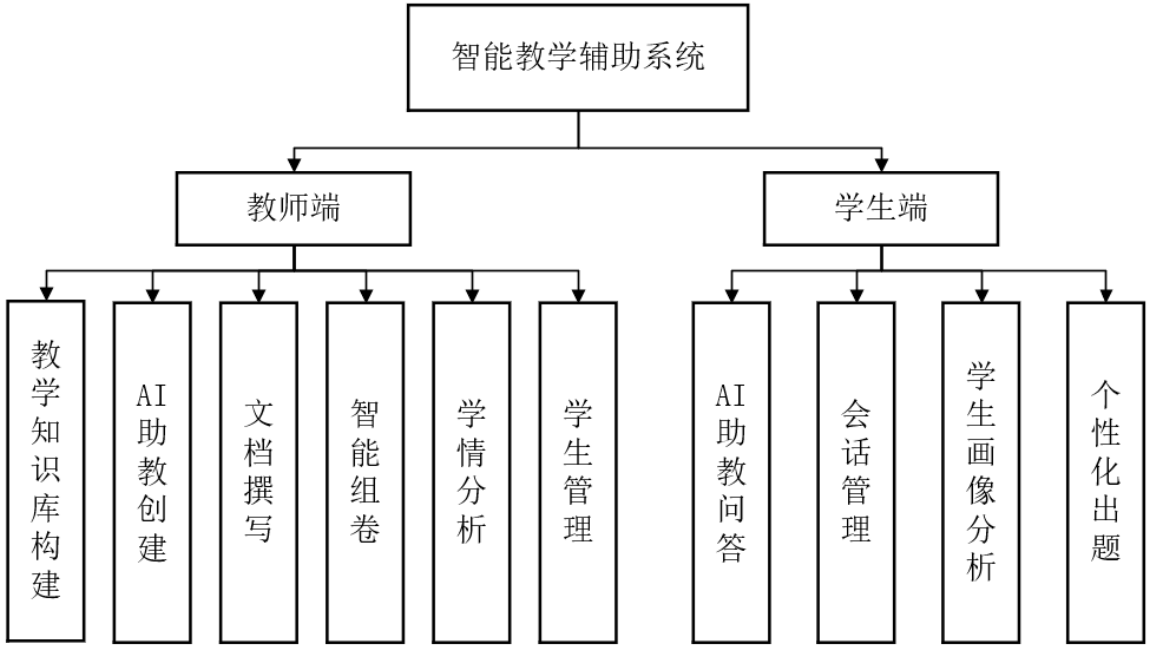
## 在线检索

- 三路召回：Query 进行**关键词、语义、视觉**三方面检索。
- 自适应融合检索：**微调 Bert 分类器**，根据 Query 特征给予三个**动态权重**。
- 重排序：检索到的多个文档页面通过 **VL 模型重排序**。



# 三、面向高职机电专业的智能教学辅助系统

- **教师端：**
  - **知识库建设：**多格式文件自动解析，集中管理机电专业教学资料。
  - **AI 助教：**可溯源的图文回答，辅助备课与答疑。
  - **资源权限：**教师私有库，可选择对学生开放。
  - **学情分析：**识别学生薄弱点，生成学习画像。
  - **文档撰写：**根据模板快速生成教案 / 报告。
- **学生端：**
  - **智能问答：**基于课程资料提供即时问答支持，辅助自主学习。
  - **图文讲解：**定位相关文档页面，结合图文内容进行讲解，提升理解效果。
  - **个性化练习：**根据学习需求生成或改写练习题，支持针对性训练。
  - **学习画像：**分析学习薄弱环节，提供个性化学习提升建议。

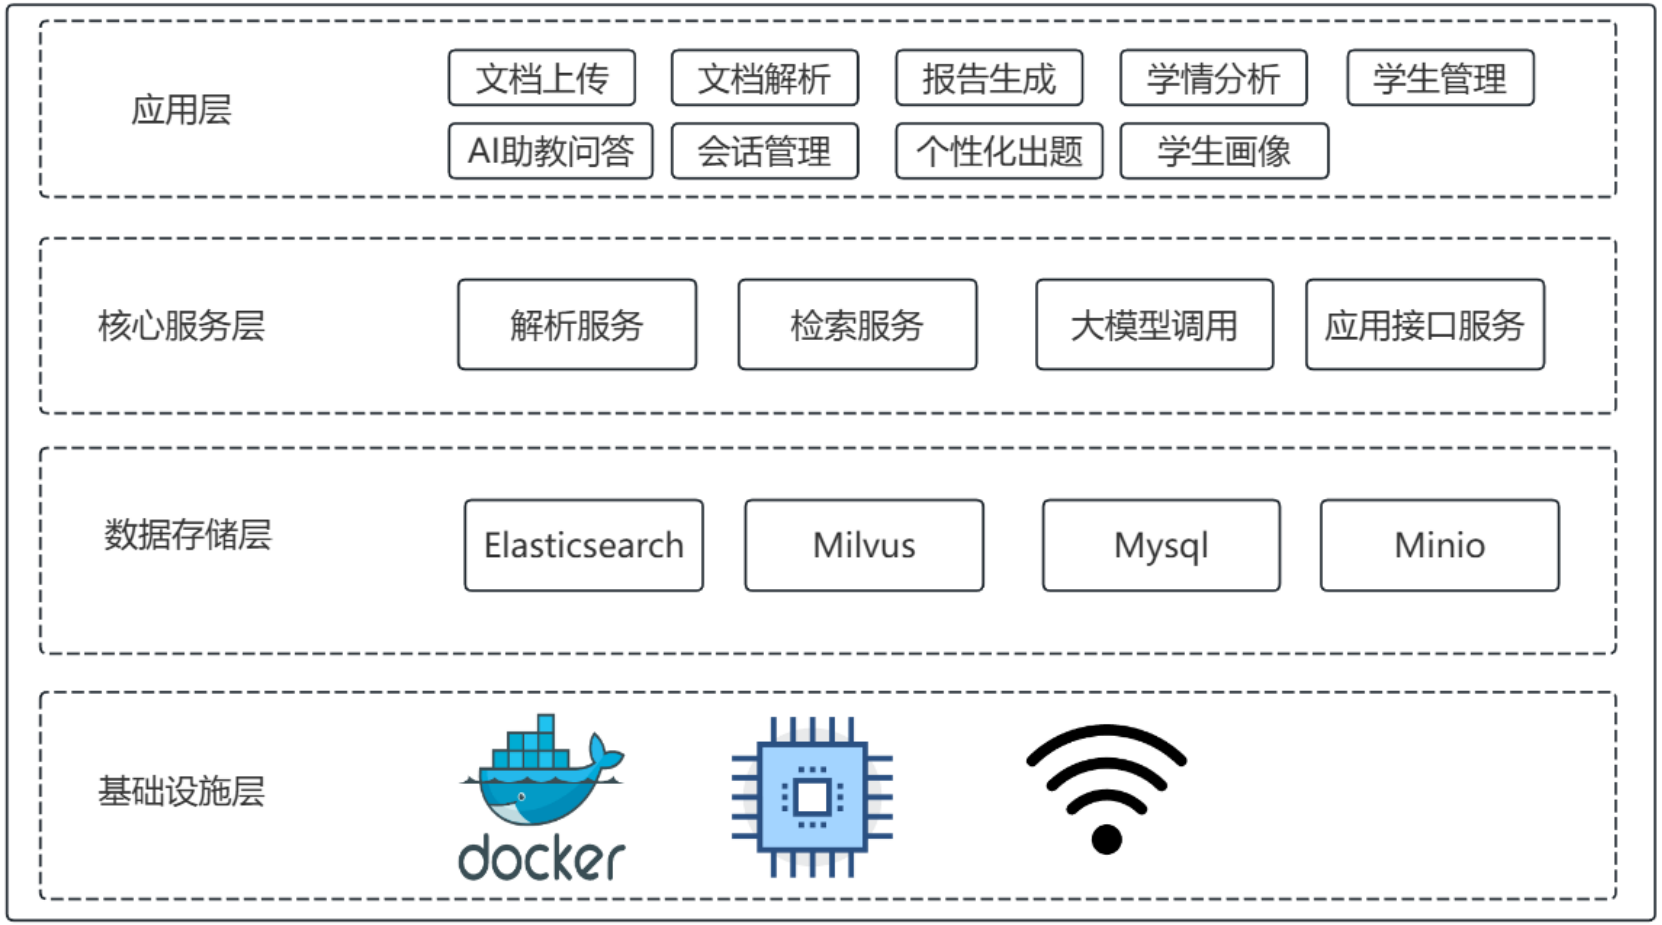



系统功能模块

## 系统总体架构与关键技术选型

系统采用分层微服务架构，自下而上保障高可用与扩展性：

- **基础设施层：** GPU 算力集群、Docker 容器化部署、私有化网络。
- **数据存储层：** ES（文本 / 向量）+ Milvus（视觉向量）+ MySQL（基础信息存储）+Minio（文件对象存储）。
- **核心服务层：** 文档解析、融合检索、大模型推理、应用接口。
- **应用交互层：** 文档上传解析、助教问答、报告撰写、学情分析、个性化出题等。



03

# 当前进展

## 数据来源

两门课程：《电工电子技术》、《电机与控制》
课件数量： 68 个 ppt 课件
文档页面： 1016 张文档页面
利用 **Qwen3-VL-32B-Instruct**，针对这些页面进行提问，每张页面可提问**关键词型、语义型、视觉型**问题，共计生成 **2722 个问题。**


```
{"query": "电机的定义是什么？", "type": "Keyword", "image_path": "0001\\page_002.png"}
{"query": "电机依据电磁感应定律实现电能的转换或传递，其主要分类包括哪些类型？", "type": "Semantic", "image_path": "0001\\page_002.png"}
{"query": "在电机的分类结构图中，交流电机的子类包括哪些？哪些子类既可以作为电动机也可以作为发电机工作？", "type": "Visual", "image_path": "
{"query": "电力拖动系统由哪五个部分组成？", "type": "Keyword", "image_path": "0001\\page_003.png"}
{"query": "在电力拖动系统中，电动机如何与传动机构和生产负载相连接？", "type": "Semantic", "image_path": "0001\\page_003.png"}
{"query": "电力拖动系统的结构框图中，电源和控制设备如何分别连接到电动机？", "type": "Visual", "image_path": "0001\\page_003.png"}
{"query": "本课程的性质是什么？", "type": "Keyword", "image_path": "0001\\page_004.png"}
{"query": "这门课程主要学习哪些电机和电器设备的基本结构与工作原理？", "type": "Semantic", "image_path": "0001\\page_004.png"}
{"query": "课程内容包括直流电机、三相异步电动机、同步电机以及变压器的电力拖动和电动机选择等内容，这些内容在文档中是如何组织和呈现的？", "type":
{"query": "电机与拖动课程涉及哪些学科知识的综合？", "type": "Keyword", "image_path": "0001\\page_005.png"}
{"query": "学习电机与拖动课程时，应如何结合理论与实践？", "type": "Semantic", "image_path": "0001\\page_005.png"}
{"query": "在学习电机与拖动课程时，应采取哪些具体的学习方法和步骤？", "type": "Visual", "image_path": "0001\\page_005.png"}
{"query": "磁感应强度的单位是什么？", "type": "Keyword", "image_path": "0001\\page_006.png"}
{"query": "磁通量是如何定义的？", "type": "Semantic", "image_path": "0001\\page_006.png"}
{"query": "磁感应强度B与磁场强度H之间的关系公式是什么？", "type": "Visual", "image_path": "0001\\page_006.png"}
{"query": "什么是磁路？", "type": "Keyword", "image_path": "0001\\page_007.png"}
{"query": "磁路是如何定义的，它与电路有什么相似之处？", "type": "Semantic", "image_path": "0001\\page_007.png"}
{"query": "在变压器和直流电机的磁路示意图中，主磁通和漏磁通分别用什么线型表示？", "type": "Visual", "image_path": "0001\\page_007.png"}
{"query": "电磁感应定律中，导体切割磁感线产生的感应电动势公式是什么？", "type": "Keyword", "image_path": "0001\\page_009.png"}
{"query": "在导体切割磁感线的情况下，感应电动势的大小与哪些物理量有关？", "type": "Semantic", "image_path": "0001\\page_009.png"}
{"query": "根据图示，如何通过右手定则判断导体在磁场中运动时产生的感应电动势方向？", "type": "Visual", "image_path": "0001\\page_009.png
{"query": "载流导体在磁场中所受的安培力公式是什么？", "type": "Keyword", "image_path": "0001\\page_008.png"}
{"query": "如何利用左手定则判断载流导体在磁场中受到的电磁力方向？", "type": "Semantic", "image_path": "0001\\page_008.png"}
```

## 实验设计

在 2722 条 query 中，随机挑选其中 2178 条数据作为训练集，通过真实 BM25 、 BGE 、 ColQwen 结果的 RRF(Reciprocal Rank Fusion, RRF) 得分作为权重，微调 Bert 分类器，让其学会**关键词问题、语义问题、视觉问题**相关的特征。在剩下 544 条 query 中进行验证 BM25 、 BGE 、 ColQwen 的 **Recall@k 和 nDCG@k** 指标。

## 评估指标

$$\text{Recall@k}=\frac{|\text{Ret}_k \cap \text{R}|}{|\text{R}|}$$ 即，前 k 个检索文档是否命中真实文档

$$\text{NDCG@}k=\frac{\text{DCG@}k}{\text{IDCG@}k}$$ 其中 $$\text{DCG@}k=\sum_{i=1}^{k}\frac{rel_i}{\log_2(i+1)}$$ ，$$\text{IDCG}k=\sum_{i=1}^{|REL|}\frac{rel_i}{\log_2(i+1)}$$ 即，评判检索是否命中的同时衡量检索排名

## 实验结果

| | Recall@1 | Recall@3 | Recall@5 | nDCG@1 | nDCG@3 | nDCG@5 |
|---|---|---|---|---|---|---|
| BM25 | 64.11 | 81.19 | 86.26 | 64.11 | 74.27 | 76.39 |
| Bge-m3 | 58.82 | 79.17 | 84.94 | 58.82 | 70.88 | 73.23 |
| ColQwen2 | 73.25 | 91.48 | 95.00 | 73.25 | 84.10 | 85.56 |
| 自适应融合检索 | **81.70** | **94.34** | **96.88** | **81.70** | **89.33** | **90.39** |

# 初步系统验证

半桥堆是什么？它有哪些主要性能指标？

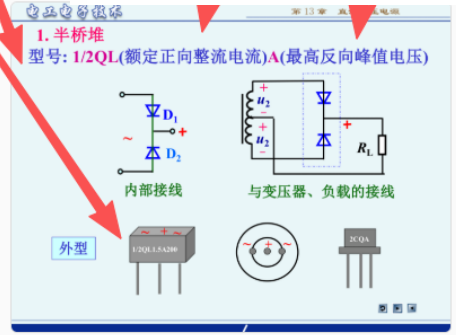
## 回答

半桥堆是一种整流电路元件，型号为1/2QL。它的主要性能
电压。例如，型号1/2QL1.5A200表示额定电流是1.5A，最高

## 相关引用

半桥堆是一种整流电路元件，型号为1/2QL，具有额定正向整流电流和最高反向峰值电压。
- **内部结构**：包含两个二极管 \(D_1\) 和 \(D_2\)，采用半桥接法。
- **功能**：实现交流到直流的整流过程，适用于直流稳压电源电路。
- **与变压器和负载的接线**：
  - 二极管桥堆的两个输入端接入变压器次级绕组电压 \(u_2\)。
  - 输出端输出整流后的直流电压，为负载 \(R_L\) 提供电源。
- **性能参数**：型号以额定正向整流电流（A）和最高反向峰值电压（kV）标识，如1/2QL1.5A200表示额定电流1.5A、最高反向峰值电压200V。
- **封装形式**：外型为方形，具有两输入、两输出引脚，另一种圆型封装也常见。

ID: 电工电子技术(第3版_林平勇)电子教案ch133-page-2.png
Score: 0.7211




ColQwen: Efficient VLM-based Document Retrieval System

Chat Area

图片中的内容是关于机器学习中支持向量机（SVM）的介绍，没有提到索建华。索建华可能是一个与该内容无关的人物。如果您有关于支持向量机或机器学习的其他问题，我会很乐意帮助您解答。

索建华的联系方式是什么

很抱歉，您提供的图片内容是关于支持向量机（SVM）和逻辑回归的比较，并没有包含关于索建华的任何信息。如果您有关于SVM和逻辑回归的问题，我会很乐意为您解答。

索建华的电话号码是多少?

索建华的电话号码是132-8341-0108。

索建华的电话号码是多少?

Send

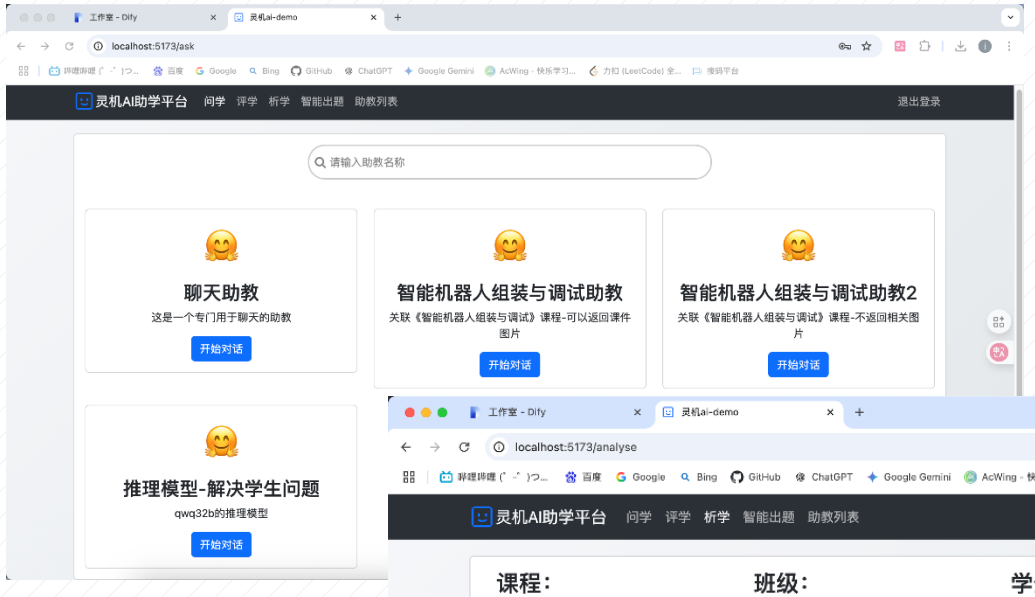
Retrieved Image



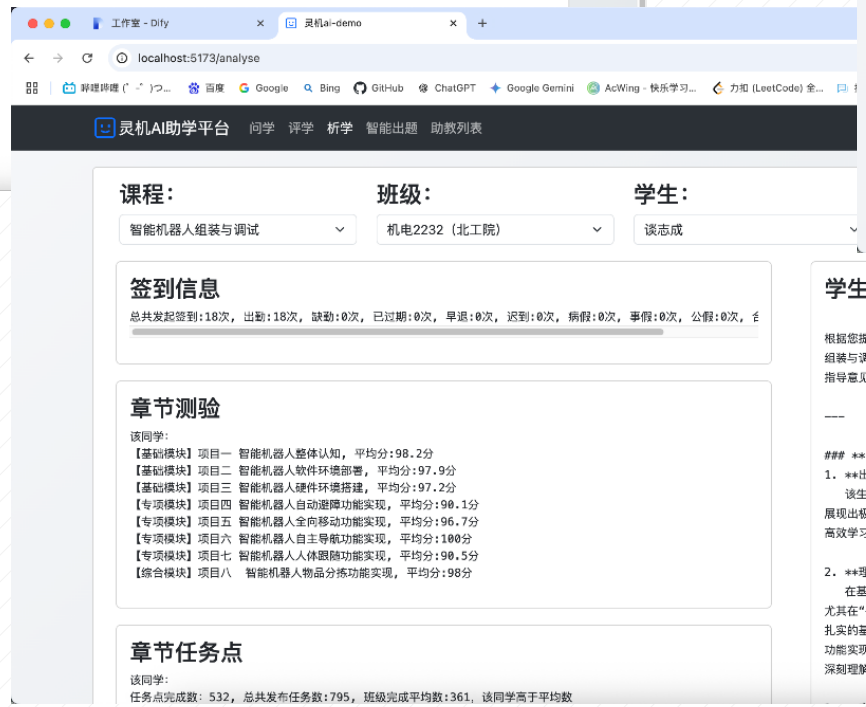
微调 ColQwen 的 MRAG

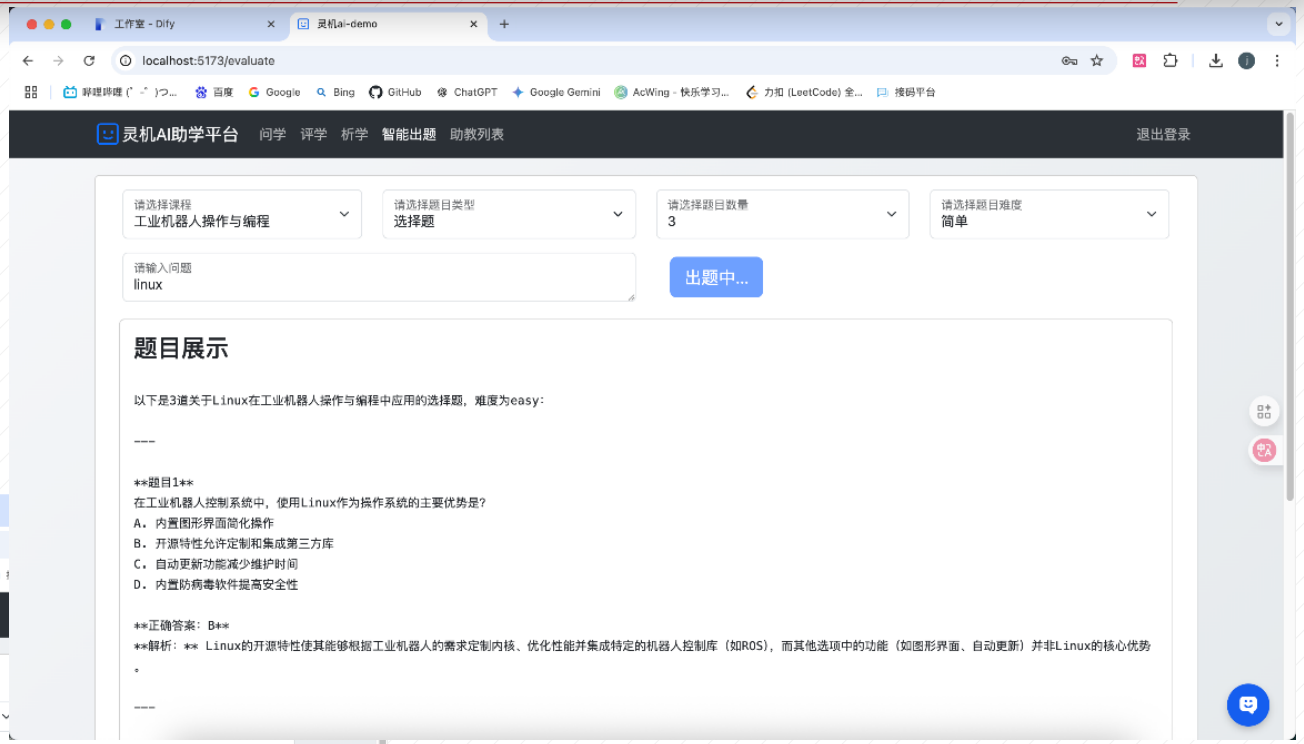
基于文档页面摘要的 MRAG

# 初步系统验证




知识库助教




智能出题

学情分析

04

# 创新点

1. 本研究拟建立“文本流 + 视觉流”文档处理机制，最大化程度保留文档页面的多模态信息。
2. 本研究拟提出一种自适应融合检索方法，通过微调 Bert 模型分配关键词、语义、视觉检索的权重，实现动态自适应的融合检索。
3. 本研究拟设计一个智能教学辅助系统，基于构建的多模态教学知识库，赋能教师教学管理与学生个性化学习。

05

# 参考文献

1. 二十大报告 ( 实录全文 ) 摘录 [J]. 广州社会主义学院学报 ,2023,(04):2+115.
2. 牢牢把握在国家发展大局中的战略定位 奋力开创黑龙江高质量发展新局面 . 人民日报， 2023-09-10(01).
3. 江峰 , 沈勇 , 李忠广 , 等 .AIGC 大模型赋能机电类专业住企实训的研究 [J]. 菏泽学院学报 ,2025,47(05):122-129.DOI:10.16393/j.cnki.37-1436/z.2025.05.013.
4. 熊英 , 袁梦 , 王威 , 等 .AI 大模型赋能高等教育数字化的现状与实现路径 [J]. 大学 ,2025,(25):16-19.
5. 吴璇 , 付涛 . 检索增强生成技术研究综述 [J]. 计算机工程与应用 ,2025,61(20):19-35.
6. Lewis P, Perez E, Piktus A, et al. Retrieval-augmented generation for knowledge-intensive nlp tasks[J]. Advances in neural information processing systems, 2020, 33: 9459-9474.
7. Gao Y, Xiong Y, Gao X, et al. Retrieval-augmented generation for large language models: A survey[J]. arXiv preprint arXiv:2312.10997, 2023, 2(1).
8. Kandpal N, Deng H, Roberts A, et al. Large language models struggle to learn long-tail knowledge[C]//International conference on machine learning. PMLR, 2023: 15696-15707.
9. Reimers N, Gurevych I. Sentence-bert: Sentence embeddings using siamese bert-networks[J]. arXiv preprint arXiv:1908.10084, 2019.
10. Chen T, Wang H, Chen S, et al. Dense x retrieval: What retrieval granularity should we use?[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. 2024: 15159-15177.
11. Zhao J, Ji Z, Qi P, et al. Meta-chunking: Learning efficient text segmentation via logical perception[J]. 2024.
12. Ma X, Gong Y, He P, et al. Query rewriting in retrieval-augmented large language models[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. 2023: 5303-5315.
13. Jagerman R, Zhuang H, Qin Z, et al. Query expansion by prompting large language models[J]. arXiv preprint arXiv:2305.03653, 2023.
14. Wang L, Yang N, Wei F. Query2doc: Query expansion with large language models[J]. arXiv preprint arXiv:2303.07678, 2023.
15. Gao L, Ma X, Lin J, et al. Precise zero-shot dense retrieval without relevance labels[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2023: 1762-1777.
16. Edge D, Trinh H, Cheng N, et al. From local to global: A graph rag approach to query-focused summarization[J]. arXiv preprint arXiv:2404.16130, 2024.
17. Guo Z, Xia L, Yu Y, et al. Lightrag: Simple and fast retrieval-augmented generation[J]. arXiv preprint arXiv:2410.05779, 2024.
18. Yu S, Tang C, Xu B, et al. Visrag: Vision-based retrieval-augmented generation on multi-modality documents[J]. arXiv preprint arXiv:2410.10594, 2024.
19. Faysse M, Sibille H, Wu T, et al. Colpali: Efficient document retrieval with vision language models[J]. arXiv preprint arXiv:2407.01449, 2024.
20. Khattab O, Zaharia M. Colbert: Efficient and effective passage search via contextualized late interaction over bert[C]//Proceedings of the 43rd International ACM SIGIR conference on research and development in Information Retrieval. 2020: 39-48.
21. Chen J , Xiao S , Zhang P ,et al.M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation[J].Findings of the Association for Computational Linguistics ACL 2024, 2024:2318-2335.DOI:10.18653/v1/2024.findings-acl.137.
22. Xu F , Shi W , Choi E .RECOMP: Improving Retrieval-Augmented LMs with Compression and Selective Augmentation[J]. 2023.
23. AMPAZIS N. Improving RAG quality for large languagemodels with topic-enhanced reranking[C]//Proceedings of theArtificial Intelligence Applications and Innovations. Cham:Springer Nature Switzerland, 2024: 74-87.
24. YU Y, PING W, LIU Z H, et al. RankRAG: unifying con-text ranking with retrieval- augmented generation in LLMs[J]. arXiv:2407.02485, 2024.

06

# 后续工作计划

| 阶段 | 起止时间 | 工作描述 | 开发成果 |
| --- | --- | --- | --- |
| Q1 | 2026.1~2026.3 | 在现有系统的基础上将**多模态知识库构建**与**自适应融合检索机制**集成，并验证其资源消耗与检索效率。 | 图文并茂的问答 |
| Q2 | 2026.4~2026.5 | 与高职教师探讨，学情分析、文档撰写的具体实现方式；基于学生使用过程中保留的数据通过 LLM 构造学生画像 | 1. 学情分析模块<br>2. 文档撰写模块<br>3. 学生画像模块<br>4. 学生出题模块 |
| Q3 | 2026.6~2026.7 | 继续完善系统 | 一套可私有化本地部署的智能教学辅助系统 |
| Q4 | 2026.9~2026.10 | 投入校园小范围试用，获取反馈 | 继续完善 |
| Q5 | 2026.10~2027.1 | 撰写硕士学位论文，准备预答辩与正式答辩 | |

# 请各位老师批评指正！