111公式章 1 节 1中国矿业大学（北京）
硕士专业学位研究生学位论文选题报告

论 文 题 目：基于 RAG 的高职机电专业智能教学辅助系统设计与实现

学　　院：人工智能学院

姓　　名：索建华

学　　号：ZQT2410405040

专业学位领域：计算机技术

研究方向：(全日制)不区分研究方向

校内导师：高文超 副教授

校外导师：王俊

研究生院学位办制

2025 年 12 月 30 日

说　明

1．选题报告为 A4 大小双面打印，于左侧装订成册。

2．选题报告的内容包括以下几个方面：

（1）阐述所选课题的来源、选题依据、在理论和实践上的意义及价值。

（2）该课题的文献综述，须详细阐述国内外有关文献在该研究方向的动态，并将查阅的资料在选题报告中列出。

（3）阐述研究内容，确定技术路线、实施方案及所采用的方法、手段和工作计划。

（4）该课题达到的预期效果和拟解决的问题。

（5）该课题在研究过程中可能遇到的困难、问题以及解决的方法和措施。

（6）估计该课题的工作量和所需经费。

3.博士选题报告字数应控制在 5000 字左右；硕士选题报告字数应控制在 3000 字左右。

目 录

1 选题背景、目的及意义.....1

2 国内外研究现状.....3

2.1 教学辅助系统研究现状.....3

2.2 RAG 研究现状.....4

2.3 知识库研究现状.....6

3 研究目标与主要研究内容.....7

3.1 研究目标.....7

3.2 主要研究内容.....8

4 实验设计.....16

4.1 实验数据集构建.....16

4.2 评估指标.....17

4.3 实验验证.....18

5 可行性分析.....19

6 创新点描述.....20

1 选题背景、目的及意义

全面推进教育数字化是党中央在二十大报告中做出的重大战略部署[1]。习近平总书记强调：“以科技创新引领产业振兴，加快形成新质生产力”[2]。作为制造业的核心支柱，机电工程领域的高质量人才培养是支撑《中国制造 2025》战略的关键要素[3]。在持续推进‘人工智能+’行动的政策导向下，高职教育正面临从单一“技能传授”向“智能赋能”的范式转型。

在教育数字化转型的浪潮中，大语言模型(Large Language Model, LLM)正在深刻重塑教育教学的形态与逻辑[4]，为破解传统教育模式的痛点提供了全新的帮助。然而高职教育领域在拥抱这一技术变革的过程中，却面临着多种困境：一方面，一线教师既要应对教学任务的常态化管理，又要兼顾学情差异化的需求，在备课、答疑、个性化指导等环节往往受限于精力与资源，难以实现智能教学的最大化；另一方面，部分学生因为教育形式固化、内容适配度不足，学习积极性与主动性长期处于较低水平，难以形成自主学习的良性闭环。

与此同时，高职教育体系内沉淀了海量异构的教学资源，以《电工电子技术》与《电机与控制》这两门课程的教学 PPT 为例，现有的教学模式仍以“教师讲授、学生被动接收”为主，缺乏高效的双向反馈机制：一方面，学生往往因心理压力而不愿公开提问；另一方面，因无法获取反馈，教师难以捕捉学生的知识

盲区。为解决上述问题，引入课程 AI 助教是一种可行路径，学生可以不必“正面提问”而获取课程知识，教师则可通过分析学生向 AI 助教的提问记录及其课堂表现，进一步开展学情分析与教学调整。鉴于通用大模型在专业领域存在知识“幻觉”与适配性不足的问题[5][8]，检索增强生成(Retrieval-Augmented Generation, RAG)技术[6]被广泛用于补充外部知识，该技术可以有效缓解通用大模型在专业领域回答不准确的问题。然而，在这些教学 PPT 中，含有大量的公式、电路图、表格、文字等多模态信息，这些内容通常交叉组织在一张 PPT 课件中，呈现出排版复杂、高度非结构化且视觉元素居多的特点，传统的 RAG 技术在面临图、表、公式等多模态元素时，往往会丢弃这些内容，导致检索精度不足，知识融合效率低等问题。此外，在系统落地过程中，数据隐私安全、Token 算力成本以及学生并发提问，也是需要解决的现实问题。

基于上述背景与现实痛点，本研究立足于北京工业职业技术学院机电专业在实际教学过程中面临的资源利用困难与智能化教学需求，以构建多模态教学知识库与检索为核心，旨在解决传统 RAG 技术在处理复杂文档时存在的局限，并围绕构建后的教学知识库开展系统化的应用研究，从而缓解教师在备课、授课、答疑中的压力，提升学生在自主学习中的理解效率与学习体验。本研究拟实现以下三个目标：(1) 整合机电专业中海量异构的教学资源，构建适配高职机电专业的多

模态教学知识库。(2) 针对传统 RAG 技术对图、表、公式等不敏感的问题，设计自适应融合检索算法，以文档页面为知识单元进行视觉语言模型问答。(3) 构建一套智能教学辅助系统，该系统可全流程私有化部署，保证数据安全与成本可控，帮助教师智能备课、学情分析，帮助学生个性化学习。

本研究兼具理论深度与应用价值。在理论层面，本研究通过构建多模态知识库，从传统以文本为主的 RAG 问答模式延伸至多模态场景，并优化 RAG 技术在处理视觉元素时的不敏感问题，为多模态检索增强生成提供更加适配的技术思路在实践层面，本研究拟开发可私有化部署的智能教学辅助系统，不仅确保了校内数据的安全性，同时也避免了云端大模型在 API Key 并发和 Token 消耗方面的限制，能够满足在校学生大规模并发访问的需求。此外，系统可在教学过程中为教师提供备课、授课、出题等辅助服务，为学生提供个性化学习支持。减轻教师工作负担，提升学生学习体验，为教育数字化转型提供了可落地的工程实现方案。

2 国内外研究现状

2.1 教学辅助系统研究现状

随着教育信息化与人工智能技术的深度融合，基于 AI 的教学辅助系统已成为现代教育技术研究的核心方向之一。

在大规模通用平台方面，以 MOOC、超星学习通、雨课堂为代表的平台，已

完成了从课程资源仓库到互动教学工具的转型。它们整合了签到、测验、资料分发、直播互动等基础教学功能，构建了相对完整的线上教学闭环。尤其值得注意的是，以科大讯飞星火教师助手和希冀 AI 大模型助教平台为代表的工具，开始将大语言模型能力深度嵌入教学场景，在自动出题、作业批阅、学情分析、报告生成等方面展现出巨大潜力。

然而，现有系统智能教学辅助系统，如已在高校广泛普及的超星学习通教师端，其 AI 功能的实践体验仍存在缺陷。虽然其集成了 AI 助教、AI 智能体、AI 学情分析等模块，但这些功能往往设计繁琐、操作路径复杂、组织结构较为混乱。对于非技术背景的教师而言，理解和熟练使用这些离散的 AI 工具需要投入大量的学习与培训时间，反而在初期增加了教学管理负担。这种高学习成本与复杂操作，严重阻碍了 AI 技术教学潜力的有效释放。

2.2 RAG 研究现状

RAG 技术的核心思想是将外部检索机制融入到大模型的生成过程中，通过非参数化的方式引入外部知识，以解决通用大模型在实时性、专业性和可解释性方面的不足。这样可以快速实现知识的增量更新，而无需对模型本体进行再训练，从而达到降低维护成本、提升问答准确性与增强系统可扩展性的目标。

RAG 技术的研究经历了从朴素到高级的演进过程[7]。早期的朴素检索增强生

成(Naive RAG)直接将检索到的多个片段一并输出给到模型参考，从而生成答案，且其分块索引规则往往单一简单，暴露出了索引阶段语义断崖、增强阶段噪声干扰以及生成阶段无法有效缓解幻觉等问题。为此，学术界提出了高级检索增强生成(Advanced RAG)，在索引层面引入语义分块[9]、命题分块[10]与 LLM 分块[11]等方法，在检索前后分别加入查询重写[12]、查询扩展[13]、假设性文档嵌入 HyDE[14][15]、融合检索[21]、文本压缩[22]、重排序[23][24]等优化手段，显著提升了系统的鲁棒性。与此同时，为了让整个 RAG 流程呈现出一种标准化的状态，对接结构化、半结构化、非结构化数据，以满足个性化的用户需求，模块化检索增强生成(Modular RAG)应用而生。通过解耦检索器、生成器、重排序器等组件，Modular RAG 将流程细分为索引、检索前、检索、检索后、重排序及生成等阶段，这一架构创新也催生了 Lang Chain、Llama Index 等开发框架的繁荣。针对长文本场景下检索片段语义割裂及用户多跳查询的难点，数据组织方式开始向图结构迁移。以 GraphRAG[16]、LightRAG[17]为代表的图检索增强生成技术，通过构建文本图谱，有效增强了知识的关联性与推理能力。

尽管文本检索增强技术已日趋成熟，但现实文档往往富含表格、图片等视觉元素，促使研究重心向多模态检索增强生成(Multimodal Retrieval-augmented Generation, MRAG)转移。早期的 MRAG 主要依赖 OCR 工具进行版面解析与图片

文字识别，但该过程流程繁琐且存在误差传播问题[18][19]。为了规避 OCR 误差，VisRAG[18]和 ColPali[19]等端到端视觉检索器被提出，这类检索器他们摒弃了繁琐的 OCR 过程，文字全部视为文档页面，统一通过视觉的方式来解析文档页面。VisRAG 认为图像的 token-embedding 中越靠后的越重要，因此给与了靠后的 token 更多的权重，并加权求所有的 token，最终将页面的多个向量压缩成了单向量表示。而 ColPali 则通过实验证明，文档页面单向量并不能全面的表示该页面的信息，因此通过多向量来表示该文档页面，并采用了与 ColBert[20]类似的延迟交互机制，充分利用了双编码的快速、交叉编码器的全面这两者优点，实现了更为充分的 token 级别的延迟交互机制。

2.3 知识库研究现状

随着大模型的发展，将外部知识库与生成模型结合的 RAG 技术逐渐成为主流方案。基于 RAG 的开源工具迅速增多，不仅提升了知识检索的准确性，也大幅降低了构建智能问答系统的门槛。

典型代表如 LangChain-Chatchat，通过文件处理、文本切分与向量检索等模块化流程，为不同领域提供可定制的 RAG 管道。FastGPT 则提供可视化工作流与 API 集成，便于开发者快速构建问答系统。RAGFlow 则以其强大的文档解析能力著称，是作为企业知识库的最佳之选。而 Dify 则提供了父子分块、混合检索等功

能，更加方便的管理工作流，帮助开发者快速的构建基于知识库的问答应用，是生产级 LLM 应用开发能力首选。

然而，这些开源的知识库框架，大多都集中在文本层面上，现实中的文档是多样且排版复杂的图文混排结构，即使像 RAGFlow 这样优秀的框架集成了 OCR 能力，也未能实现真正意义上的多模态，单纯的通过 OCR 来进行解析文字，并未理解图表的真正含义。

3 研究目标与主要研究内容

3.1 研究目标

本研究面向北京工业职业技术学院机电专业的教学场景，拟定实现以下三个目标：

(1) 构建多模态教学知识库：完成对多格式文件（PDF、PPT、DOC、图片等）教学资料的上传、解析、存储、嵌入，最大化程度保留教学资料中的图、表公式等多模态信息，搭建多模态的教学知识库。

(2) 研究自适应融合检索算法：基于关键词、语义与视觉特征，进行多路召回，并设计自适应网络，动态调整三路权重，将检索粒度扩大到文档页面，保留完整的上下文多模态信息，进行视觉语言模型问答。

(3) 搭建智能教学辅助系统：基于多模态教学知识库与自适应融合检索算法，

构建本地私有化部署的 RAG 应用，搭建智能教学辅助系统，辅助教师备课、授课、学情分析，帮助学生个性化学习。

3.2 主要研究内容

3.2.1 基于文本流与视觉流的多模态知识库建模

针对高职机电专业教学资源的非结构化且包含丰富的视觉元素特点，设计并实现一套“文本流+视觉流”多模态数据处理流水线，其具体流程如图 1所示。

对于不同格式的资料数据，为了后续方便处理，将其转化为统一的 PDF 格式，并对 PDF 进行文档截图，定义文档页面为一个知识单元，对一个知识单元展开文本流与视觉流的处理。

对于文本流，集成 MinerU 解析工具，利用其文档解析能力精准提取页面中的文本信息，并基于固定分块与重叠机制，对文本信息进行 chunk 与 embedding，使用 jieba 分词器提取 chunk 中的关键词，最终将文本 chunk 的关键词与向量存储至 ElasticSearch 中。

对于视觉流，引入 ColQwen 视觉检索模型，针对文档页面进行细粒度的嵌入表示。ColQwen 嵌入模型将单张文档页面转化为多个 token-embedding，为了减少多向量的存储与计算压力，可以对其进行 token-pooling。

对于上述两种流信息，设计数据映射机制，通过元数据将段落级的文本索引

与 Token 级的页面视觉索引，关联到对应的文档页面。

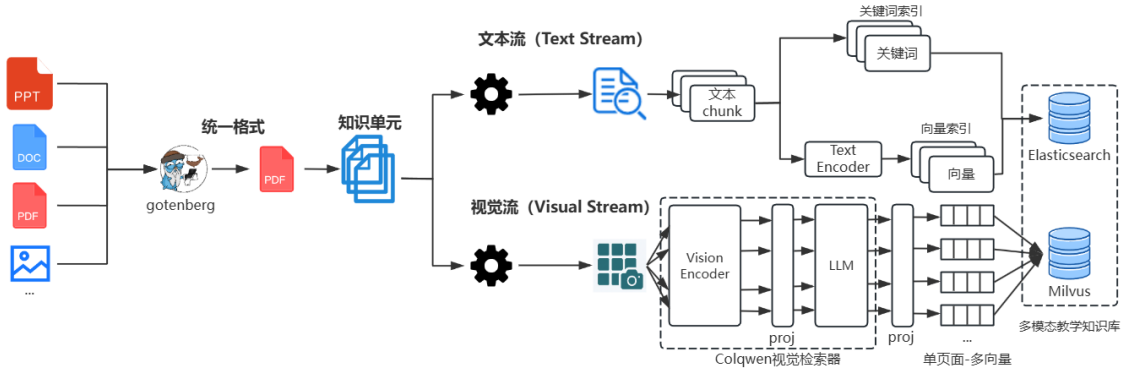


图 1 构建多模态教学知识库

3.2.2 基于查询自适应的融合检索算法

为解决解决单一检索固有的缺陷，从关键词、语义、视觉三方面进行多路召回，并微调 Bert 分类器，根据 Query 的特征动态输出关键词、语义、视觉三方面的权重信息。实现根据 Query 自适应修改权重，动态融合来自关键词、语义、视觉三方面的分数信息，其具体流程如图 2所示。

对于关键词检索，使用 BM25 检索器，这是一种基于概率检索模型的经典文本匹配方法，主要衡量查询词在文档中的词频与区分能力。对于查询 $Q=\{q_1,\cdots,q_m\}$ 文档为 D，BM25 的得分定义为：

$$\mathrm{BM25}(Q,D)=\sum_{i=1}^{m}\mathrm{IDF}(q_i)\cdot\frac{f(q_i,D)(k_1+1)}{f(q_i,D)+k_1\left(1-b+b\cdot\frac{|D|}{\mathrm{avgdl}}\right)} \quad 22\backslash*\ \mathrm{MERGEFORMAT}\ ()$$

$$\mathrm{IDF}(q_i)=\log\frac{N-n(q_i)+0.5}{n(q_i)+0.5} \quad 33\backslash*\ \mathrm{MERGEFORMAT}\ ()$$

其中，$Q=\{q_1,\cdots,q_m\}$ 表示查询词项集合，$f(q_i,D)$ 表示词项 q_i 在文档 D 中的出现频率，|D| 为文档长度，^{avgdl} 为语料库中文档的平均长度，N 为文档总数，$n(q_i)$ 为包含词项 q_i 的文档数量，k_1 和 b 为平滑参数。

对于语义检索，使用 BGE-M3 模型，这是一个基于深度学习的文本嵌入模型，其检索得分的计算公式为：

$$\text{Sim}(Q,D)=\cos(\mathbf{q},\mathbf{d})=\frac{\mathbf{q}\cdot\mathbf{d}}{|\mathbf{q}||\mathbf{d}|} \quad 44\backslash^{*}\ \text{MERGEFORMAT}\ ()$$

对于视觉检索，使用 ColQwen 模型，这是一个视觉嵌入模型，通过将单张页面分割为多个 Patch，并将多个 Patch 通过 Vision Encoder 转化为多个向量，最后通过语言模型将其转化为多个 token-embedding，其计算分数采用了延迟交互机制，集成了双编码器和交叉编码器的优点，对于 $Q=\{q_1,\cdots,q_m\}$ 与 $D=\{d_1,\cdots,d_n\}$，其计算公式如下：

$$\text{Sim}(Q,D)=\sum_{i=1}^{m}\max_{j=1,\cdots,n}\left(\mathbf{e}_{q_i}\cdot\mathbf{e}_{d_j}\right) \quad 55\backslash^{*}\ \text{MERGEFORMAT}\ ()$$

对于关键词、语义，两者检索到的是 chunk-level 的信息，而视觉检索器，检索到的是 page-level 的信息，为了对齐两者的粒度并实现“图文并茂”的视觉文档问答机制，我们取 chunk-level 所在页面的最大得分作为该页面的得分，将文本流的信息对齐至 page-level。将三者检索到的页面得分，通过 Min-Max 算法进行归一化。

$$\hat{x} = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad 66\backslash * \text{ MERGEFORMAT ()}$$

其中 x 表示原始分数，$x_{\min}$ 表示所有样本中的最小值，$x_{\max}$ 表示所有样本中的最大值，$\hat{x}$ 表示归一化后的分数。

为了让权重能够根据 Query 自适应分配，本文选择用训练集中的根据真实的 BM25、BGE、ColQwen 三者排名的倒数排序融合(Reciprocal rank fusion, RRF)得分作为权重，Query 通过 Bert-Base-Chinese 模型，取得其中的[CLS]位置所对应的标记，经过线性层进行预测。

最终通过微调后的 Bert 模型输出 Query 三方面的权重信息，将三者分数进行融合。

$$\text{Fusion}(Q, D) = \alpha \cdot \hat{x}^{\text{BM25}} + \beta \cdot \hat{x}^{\text{Dense}} + \gamma \cdot \hat{x}^{\text{Visual}} \quad 77\backslash * \text{ MERGEFORMAT ()}$$

最后，检索到的多个页面根据融合得分进行排序，并通过本地私有化部署的 Qwen2.5-VL 模型进行 Top-K 重排序，剔除检索阶段的噪声，提升最后上下文的质量。

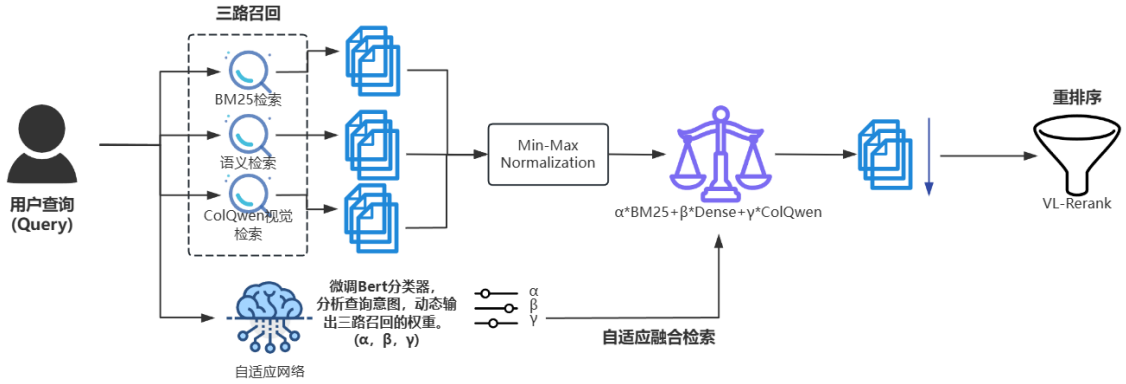


图 2 自适应融合检索算法

3.2.3 面向高职机电专业的智能教学辅助系统

本研究拟基于微服务架构与私有化部署方案，设计并实现一套面向机电专业的智能教学辅助系统。该系统设计依赖前文所述的多模态数据处理与检索算法，旨在构建连接教师与学生的智能化教学环境。

(1) 面向角色的系统功能建模

针对机电专业教学场景中不同角色的核心诉求，系统划分为教师端与学生端两大功能子系统，如图 3所示。

a) 教师端功能设计：

①多模态知识库构建：针对机电专业教学设计大量非结构化资料，设计支持多格式文件上传、解析与管理的知识库模块，实现从文件存储到知识沉淀的转化。

② AI 教学助手：AI 助教可基于一个或多个知识库来创建，使其能够基于私有知识库提供“图文并茂”的精准回答，并支持溯源至原始课件，确保教学内容的严谨性。

③教学文档撰写：针对“课程标准—授课计划—教案—试卷”全流程文档撰写繁琐且逻辑耦合度高的问题，设计基于 RAG 的文档自动化生成与动态一致性维护功能。

④学情分析：基于学生在本系统与外部系统的交互数据，如问答、习题作答、学生画像、超星签到、测验等数据，利用 LLM 构建包含三维能力目标与思政目标的学情画像，辅助教师动态调整教学进度。

b) 学生端功能设计：

①助教智能问答：基于学生配置课程 AI 助教，能够基于已有的资料，利用检索算法，快速定位到相关的文档页面，提供“图文并茂”形式的讲解。

②个性化习题陪练：针对学生的差异化需求，系统需根据学生的需求、答题情况、学生画像、已有习题库等信息，动态调整题目，陪伴学生练习巩固。

③个性化资源推荐：学生在不断使用系统的过程中，需构造出当前学生的用户画像，识别学生的薄弱点，进而进行精准化的资源推荐。

c) 系统非功能需求设计：

①数据安全：为了保障私有教学知识库的安全性，系统需采用本地私有化部署方案。在问答生成的关键阶段，利用本地服务器部署的大语言模型（LLM）或多模态模型（VLM）进行推理，有效解决学生数据泄露和课程数据的隐私与安全问题。

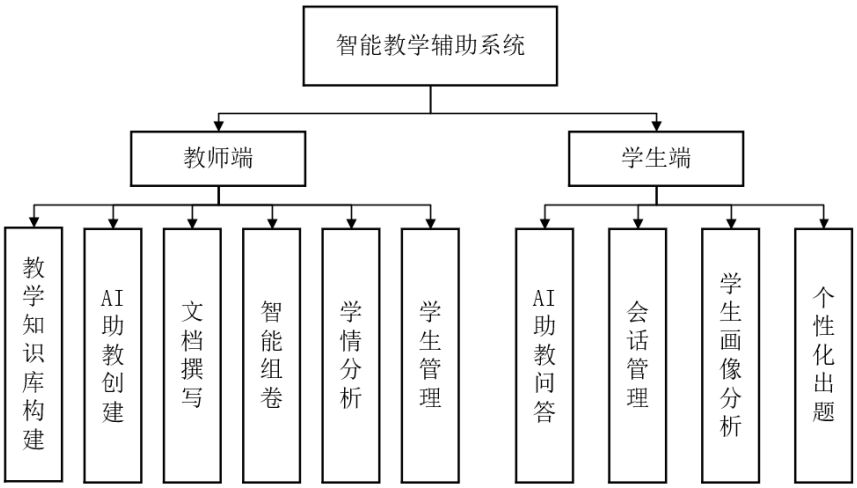


图 3 系统功能模块

(2) 基于微服务的系统分层架构设计

为保障系统的高可用性、可扩展性与数据安全性，本研究拟采用前后端分离的微服务架构，系统自下而上划分为四层，如图 4所示。

基础设施层：包含 GPU 服务器，私有化网络，容器化部署 docker/k8s 等。

数据存储层：Elasticsearch 负责存储文本 chunk 的关键词与向量，Milvus 负责存储 ColQwen 模型编码的文档视觉向量，MySQL 负责基础信息，Minio 负责存储本地文件。

核心服务层：提供文档解析、检索、大模型调用、API 接口等服务。

应用层：Web 端可视化界面，方便教师和学生简单操作系统。

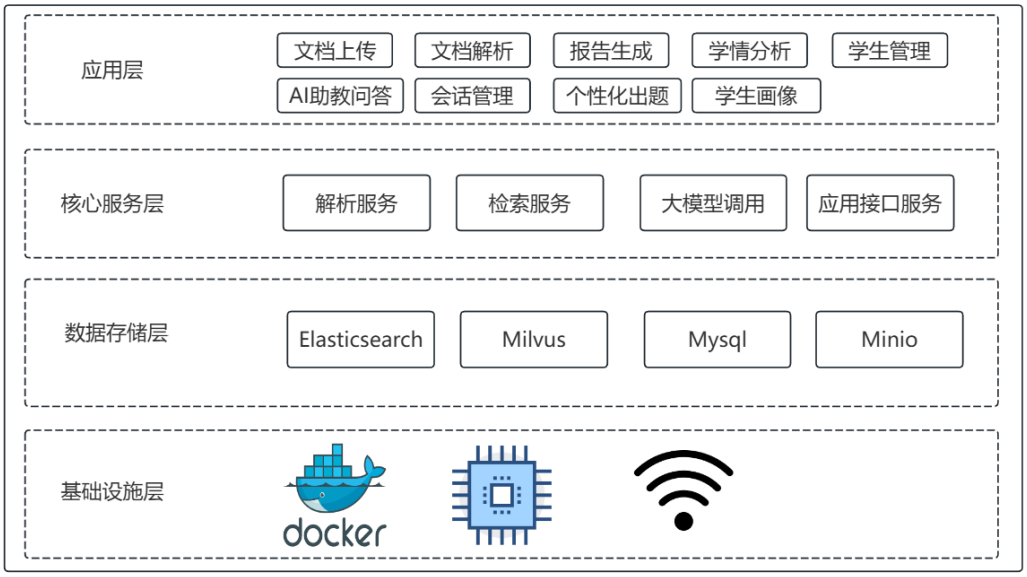


图 4 系统架构图

(3) 关键技术选型与实现路线

为实现上述功能与架构，拟采用以下主流技术栈进行工程实现：

前端开发框架：采用 React 框架结合 TypeScript，利用其组件化特性构建响应式交互界面。

后端开发框架：采用 Flask 轻量级框架，便于快速集成 Python 生态下的 AI 算法库。

AI 框架：利用 LangChain 构建 RAG 检索流水线；利用 AutoGen 构建复杂的 Agent 智能体工作流；采用 vLLM 框架优化本地大模型的推理吞吐量。

核心模型选择：(1) 基座模型选用 Qwen2.5-7B-Instruct 与 Qwen2.5-7B-VL-Instruct，该模型在文本理解和图像理解上表现表现优异，且参数量适中，适合私有化部署。(2) 文本的嵌入模型选用 Bge 系列，如 Bge-m3、Bge-zh-v1.5，视觉的

嵌入模型选用 ColQwen。(3) 重排序模型选用 Bge-Rerank 或使用 VLM 进行重排序

运维部署：使用 Docker Compose 进行服务编排，利用 Nginx 进行反向代理与负载均衡。

4 实验设计

4.1 实验数据集构建

为全面验证本文提出的自适应融合检索的有效性，拟定采用“公开基准+垂直自建”双重验证策略。

通用基准选用 Vidore Benchmark[19]（包含 DocVQA, InfoQA 等子集），用于验证检索算法在标准多模态检索任务上的技术竞争力，确保方法达到行业主流水平。

垂域自建数据集选用北京工业职业技术学院中的《电工电子技术》、《电机与控制》两门 PPT 课件作为资料开展实验，利用大模型辅助标注+人工验证的方式构建 Query-图片对，涵盖关键词型、语义型、视觉型三类问题。

目前已基于《电工电子技术》、《电机与控制》两门课程，共计 68 个 PPT 课件，1016 张文档截图，利用 Qwen3-VL-32B-Instruct 进行提问，共计生成 2722 个问题，数据如图 5所示。

```
{"query": "电机的定义是什么？", "type": "Keyword", "image_path": "0001\\page_002.png"}
{"query": "电机依据电磁感应定律实现电能的转换或传递，其主要分类包括哪些类型？", "type": "Semantic", "image_path": "0001\\page_002.png"}
{"query": "在电机的分类结构图中，交流电机的子类包括哪些？哪些子类既可以作为电动机也可以作为发电机工作？", "type": "Visual", "image_path": "
{"query": "电力拖动系统由哪五个部分组成？", "type": "Keyword", "image_path": "0001\\page_003.png"}
{"query": "在电力拖动系统中，电动机如何与传动机构和生产负载相连接？", "type": "Semantic", "image_path": "0001\\page_003.png"}
{"query": "电力拖动系统的结构框图中，电源和控制设备如何分别连接到电动机？", "type": "Visual", "image_path": "0001\\page_003.png"}
{"query": "本课程的性质是什么？", "type": "Keyword", "image_path": "0001\\page_004.png"}
{"query": "这门课程主要学习哪些电机和电器设备的基本结构与工作原理？", "type": "Semantic", "image_path": "0001\\page_004.png"}
{"query": "课程内容包括直流电机、三相异步电动机、同步电机以及变压器的电力拖动和电动机选择等内容，这些内容在文档中是如何组织和呈现的？", "type":
{"query": "电机与拖动课程涉及哪些学科知识的综合？", "type": "Keyword", "image_path": "0001\\page_005.png"}
{"query": "学习电机与拖动课程时，应如何结合理论与实践？", "type": "Semantic", "image_path": "0001\\page_005.png"}
{"query": "在学习电机与拖动课程时，应采取哪些具体的学习方法和步骤？", "type": "Visual", "image_path": "0001\\page_005.png"}
{"query": "磁感应强度的单位是什么？", "type": "Keyword", "image_path": "0001\\page_006.png"}
{"query": "磁通量是如何定义的？", "type": "Semantic", "image_path": "0001\\page_006.png"}
{"query": "磁感应强度B与磁场强度H之间的关系公式是什么？", "type": "Visual", "image_path": "0001\\page_006.png"}
{"query": "什么是磁路？", "type": "Keyword", "image_path": "0001\\page_007.png"}
{"query": "磁路是如何定义的，它与电路有什么相似之处？", "type": "Semantic", "image_path": "0001\\page_007.png"}
{"query": "在变压器和直流电机的磁路示意图中，主磁通和漏磁通分别用什么线型表示？", "type": "Visual", "image_path": "0001\\page_007.png"}
{"query": "电磁感应定律中，导体切割磁感线产生的感应电动势公式是什么？", "type": "Keyword", "image_path": "0001\\page_009.png"}
{"query": "在导体切割磁感线的情况下，感应电动势的大小与哪些物理量有关？", "type": "Semantic", "image_path": "0001\\page_009.png"}
{"query": "根据图示，如何通过右手定则判断导体在磁场中运动时产生的感应电动势方向？", "type": "Visual", "image_path": "0001\\page_009.png
{"query": "载流导体在磁场中所受的安培力公式是什么？", "type": "Keyword", "image_path": "0001\\page_008.png"}
{"query": "如何利用左手定则判断载流导体在磁场中受到的电磁力方向？", "type": "Semantic", "image_path": "0001\\page_008.png"}
```


图 5 课程数据集

4.2 评估指标

在信息检索领域，常用的评估指标有 Recall@k，nDCG@k。

Recall@k 衡量的是检索系统在前 k 个推荐结果中，成功检索出的相关文档占数据库中所有相关文档的比例。

$$\text{Recall@k}=\frac{|\text{Ret}_k \cap \text{R}|}{|\text{R}|} \qquad 88\backslash* \text{ MERGEFORMAT ()}$$

其中$|Ret_k \cap R|$表示前 k 个结果中相关文档的数量，$|R|$表示该查询对应的总相关文档数量。

NDCG@k(Normalized Discounted Cumulative Gain，NDCG)则是一个更精细的指标，它不仅关心相关文档是否被检索到，还关心它们出现的位置。它的核心思想是，排序越靠前的文档，其贡献应当更大，而随着位置向后，文档的价值应当以对数速度衰减。

NDCG@k 的计算需要先定义折损累计增益（Discounted Cumulative Gain, DCG）。对于一个查询，其前 k 个位置的 DCG 定义为：

$$\mathrm{DCG@}k = \sum_{i=1}^{k} \frac{rel_i}{\log_2(i+1)} \qquad 99\backslash* \text{ MERGEFORMAT ()}$$

其中 k 表示模型返回结果，i 表示每个结果对应的排序位置，rel_i 表示第 i 个位置上的文档相关性分数。

由于不同查询的相关文档数量和质量差异较大，直接使用 DCG 无法在不同查询间进行公平比较。因此，需要使用理想折损累计增益（Ideal DCG, IDCG）进行归一化。IDCG@k 是指在相关文档按照相关性分数从高到低理想排序的情况下，前 k 个位置获得的 DCG 值：

$$\mathrm{IDCG}k = \sum_{i=1}^{|REL|} \frac{rel_i}{\log_2(i+1)} \qquad 1010\backslash* \text{ MERGEFORMAT ()}$$

其中 $|REL|$ 表示按相关性降序排列的文档列表。

最终，NDCG@k 计算为 DCG@k 与 IDCG@k 的比值，取值范围为[0, 1]：

$$\mathrm{NDCG@}k = \frac{\mathrm{DCG@}k}{\mathrm{IDCG@}k} \qquad 1111\backslash* \text{ MERGEFORMAT ()}$$

该值越接近 1，说明系统的排序结果越接近理想状态。

4.3 实验验证

选用 BM25、Bge-M3，ColQwen 作为基线方法进行对比，在《电工电子技

术》、《电机与控制》自建数据集上进行验证，2722 条数据集中，挑选其中 2178 条数据作为训练集，以 BM25、BGE、ColQwen 真实结果的 RRF(Reciprocal Rank Fusion, RRF)作为权重，训练 Bert 分类器，在剩下的 544 条数据中展开实验，实验结果如表 1所示。

表 1 实验结果

	Recall@1	Recall@3	Recall@5	nDCG@1	nDCG@3	nDCG@5
BM25	64.11	81.19	86.26	64.11	74.27	76.39
Bge-m3	58.82	79.17	84.94	58.82	70.88	73.23
ColQwen2	73.25	91.48	95.00	73.25	84.10	85.56
Ours	**81.70**	**94.34**	**96.88**	**81.70**	**89.33**	**90.39**

5 可行性分析

在技术基础方面，当前开源的 Qwen 系列大模型在文本理解与图像理解上的表现已接近商业闭源模型的水平。结合 RAG 技术，可显著降低大模型在专业问答中的“幻觉”风险，从而为机电类课程提供更加可靠的知识问答体验。

在数据处理层面，机电专业文档中普遍包含公式、电路图、结构图等复杂视觉元素，对解析能力提出较高要求。针对这一难点，PaddleOCR、MinerU 等开源 OCR 工具能够实现精准的版面分析和要素抽取；Bge-m3、Bge-zh-v1.5 等文本嵌入模型可对一段文本进行准确的向量表示；ColPali、ColQwen 等视觉检索器则对文档截图进行更细粒度的嵌入表示，为多模态 RAG 提供精确的上下文支撑。

在硬件与部署方面，北京工业职业技术学院现有内网服务器配置为 4×A40 单

机多卡 GPU 服务器，可满足多数主流大模型的本地推理需求，为数据安全、隐私保护和网络隔离场景提供可靠保障。结合 vLLM 推理加速框架，可进一步提升模型推理的吞吐量与响应速度，实现低延迟、高并发的部署效果。

综上所述，从技术基础、数据处理、硬件算力部署来看，构建一套面向高职机电专业的基于 RAG 的智能教学辅助系统具有良好的可行性。

6 创新点描述

本研究立足北京工业职业技术学院机电专业，针对现有教学资源利用率低及智能化教学需求，拟构建基于 RAG 的高职机电专业智能教学辅助系统，其创新点如下：

1、针对机电专业教学资料非结构化、排版复杂、视觉元素居多的特点，设计“文本流+视觉流”的文档处理机制，最大化程度保留文档页面信息。

2、为缓解单一检索的缺陷，提出自适应融合检索算法，通过微调 Bert 模型分配关键词、语义、视觉三方面的权重，实现动态自适应融合。

3、搭建智能教学辅助系统。基于多模态教学知识库，搭建可私有化部署的教学辅助系统，在保障数据安全与成本可控的前提下，集成 AI 助教问答、文档撰写、智能出题及学情分析等功能模块，为教师教学减负与学生个性化学习提供实质性的工具支持。

参考文献

[1] 二十大报告(实录全文)摘录[J].广州社会主义学院学报,2023,(04):2+115.

[2] 牢牢把握在国家发展大局中的战略定位 奋力开创黑龙江高质量发展新局面. 人民日报，2023-09-10(01).

[3] 江峰,沈勇,李忠广,等.AIGC 大模型赋能机电类专业住企实训的研究[J].菏泽学院学报,2025,47(05):122-129.DOI:10.16393/j.cnki.37-1436/z.2025.05.013.

[4] 熊英,袁梦,王威,等.AI 大模型赋能高等教育数字化的现状与实现路径[J].大学,2025,(25):16-19.

[5] 吴璇,付涛.检索增强生成技术研究综述[J].计算机工程与应用,2025,61(20):19-35.

[6] Lewis P, Perez E, Piktus A, et al. Retrieval-augmented generation for knowledge-intensive nlp tasks[J]. Advances in neural information processing systems, 2020, 33: 9459-9474.

[7] Gao Y, Xiong Y, Gao X, et al. Retrieval-augmented generation for large language models: A survey[J]. arXiv preprint arXiv:2312.10997, 2023, 2(1).

[8] Kandpal N, Deng H, Roberts A, et al. Large language models struggle to learn long-tail knowledge[C]//International conference on machine learning. PMLR, 2023: 15696-15707.

[9] Reimers N, Gurevych I. Sentence-bert: Sentence embeddings using siamese bert-networks[J]. arXiv preprint arXiv:1908.10084, 2019.

[10] Chen T, Wang H, Chen S, et al. Dense x retrieval: What retrieval granularity should we use?[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. 2024: 15159-15177.

[11] Zhao J, Ji Z, Qi P, et al. Meta-chunking: Learning efficient text segmentation via logical perception[J]. 2024.

[12] Ma X, Gong Y, He P, et al. Query rewriting in retrieval-augmented large language models[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. 2023: 5303-5315.

[13] Jagerman R, Zhuang H, Qin Z, et al. Query expansion by prompting large language models[J]. arXiv preprint arXiv:2305.03653, 2023.

[14] Wang L, Yang N, Wei F. Query2doc: Query expansion with large language

models[J]. arXiv preprint arXiv:2303.07678, 2023.

[15] Gao L, Ma X, Lin J, et al. Precise zero-shot dense retrieval without relevance labels[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2023: 1762-1777.

[16] Edge D, Trinh H, Cheng N, et al. From local to global: A graph rag approach to query-focused summarization[J]. arXiv preprint arXiv:2404.16130, 2024.

[17] Guo Z, Xia L, Yu Y, et al. Lightrag: Simple and fast retrieval-augmented generation[J]. arXiv preprint arXiv:2410.05779, 2024.

[18] Yu S, Tang C, Xu B, et al. Visrag: Vision-based retrieval-augmented generation on multi-modality documents[J]. arXiv preprint arXiv:2410.10594, 2024.

[19] Faysse M, Sibille H, Wu T, et al. Colpali: Efficient document retrieval with vision language models[J]. arXiv preprint arXiv:2407.01449, 2024.

[20] Khattab O, Zaharia M. Colbert: Efficient and effective passage search via contextualized late interaction over bert[C]//Proceedings of the 43rd International ACM SIGIR conference on research and development in Information Retrieval. 2020: 39-48.

[21] Chen J , Xiao S , Zhang P ,et al.M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation[J].Findings of the Association for Computational Linguistics ACL 2024, 2024:2318-2335.DOI:10.18653/v1/2024.findings-acl.137.

[22] Xu F , Shi W , Choi E .RECOMP: Improving Retrieval-Augmented LMs with Compression and Selective Augmentation[J]. 2023.

[23] AMPAZIS N. Improving RAG quality for large languagemodels with topic-enhanced reranking[C]//Proceedings of theArtificial Intelligence Applications and Innovations. Cham:Springer Nature Switzerland, 2024: 74-87.

[24] YU Y, PING W, LIU Z H, et al. RankRAG: unifying con-text ranking with retrieval-augmented generation in LLMs[J]. arXiv:2407.02485, 2024.